Document : Module Audit Interne — Design Multi-Agents Open Source (Stack Free)

📌Objectif

Mettre en place un module Audit Interne fondé sur un flux multi-agents, opérant exclusivement sur une stack open-source/free, avec une logique évolutive centrée d'abord sur la robustesse des données puis sur les capacités IA. Le focus est dirigé sur toutes les étapes appartenant au module Audit Interne : ingestion, traitement multimodal, gestion des exigences, cartographie des preuves, évaluation, gestion des non-conformités, CAPA, rapport final.

🧩 Stack technique retenue

- **Supabase** : base relationnelle (PostgreSQL), source de vérité des données métiers et metadata
- **Milvus** : base vectorielle pour RAG / similarité sémantique, référence de contenu document
- **Redis** : event bus, cache léger, orchestration à grain fin entre agents
- **LLM open source** : ex: Llama 3, Mistral via Ollama ou vLLM pour raisonnements structurés et validations

🧠 Approche : prise en charge de la multimodalité (audit réel)

En contexte audit, les preuves et documents proviennent de formats disparates, chacun nécessitant un traitement adapté. Pour maximiser la fiabilité:

Type	Exemple	Traitement proposé
📄 PDF	Procédures, politiques	OCR + chunking + embeddings
📊 Excel	Checklist	parsing structuré
📝 Word	Rapport	extraction texte
🖼️ Image	Photo preuve	OCR
📧 Email	preuve de communication	parsing

| 🗃️ Métadonnées | version, date, owner | stockage structuré |

Le principe est explicite : la structure arrive avant le jugement IA. Sans contenu tracé, les garanties d'audit deviennent fragilisées.

🏗️ Architecture globale (réaliste pour du production "amanagé")

```
User → API → Supabase (data)
            ↓
        File Storage
            ↓
      Preprocessing Service
            ↓
      Embeddings → Milvus
            ↓
        Agents (LLM)
            ↓
        Redis Events
```

Cette architecture permet de conserver une trace complète : fichiers, versions, métadonnées, extraits vectorialisés, décisions IA et séquencement d'activités via événements.

🚀 Roadmap étape par étape — uniquement Module Audit Interne

✅ PHASE 1 — DATA MODEL DESIGN (CRITIQUE)

Avant toute orchestration IA, il est fondamental de stabiliser un schéma compatible audit : suivi d'historique, traçabilité, relations entre exigences, preuves, NC, CAPA et statut.

STEP 1 — Modélisation Supabase (tables principales)
1️⃣ `audits`
- Input : création d'audit
- Output : `audit_id`

2️⃣ `checklists`
Field	Type
id	uuid
audit_id	fk
requirement_id	string
description	text
criticality	enum
status	enum

3️⃣ `documents`
Field	Type
---	
id	uuid
name	text
version	text
owner	text
upload_date	timestamp
file_path	text

4️⃣ `evidence_mapping`
- Colonnes : `requirement_id`, `document_id`, `similarity_score`
- Permet la traçabilité explicite d'à quels documents une exigence a été reliée, avec score.

5️⃣ `non_conformities`
- `requirement_id`, `severity`, `description`, `status`

6️⃣ `capa_actions`
- `nc_id`, `responsible`, `due_date`, `status`, `proof_document`

OUTPUT attendus de cette phase
- Schéma DB stable et audit-friendly
- Relations explicites (audit → exigences → preuves → NC → CAPA)
- Fondation prête pour opérations structurées des agents

✅ PHASE 2 — DOCUMENT INGESTION PIPELINE (multimodal)

Cette phase rend exploitables les fichiers auditables.

STEP 2 — Upload & Préprocessing
INPUTS : PDF, Excel, Word, Image
PROCESS :
- Extraction texte : pdfplumber, python-docx, pandas, Tesseract (OCR)

- Nettoyage
- Chunking typiquement 500–800 tokens
- Embeddings (ex : bge-small, e5-base)
- Stockage :
  - Texte + structure → Supabase
  - Vecteurs → Milvus
  - Metadata → Supabase

OUTPUT :

Milvus stocke au minimum :
```json
{
  "chunk_id": "...",
  "embedding_vector": [...],
  "document_id": "...",
  "requirement_reference": null
}
```
Supabase conserve documents + metadata structured.

✅ PHASE 3 — AGENT 1 : CHECKLIST MANAGER

Agent responsable de rendre “machine-readable” la grille d’audit.

INPUT : Excel checklist OU PDF structuré
PROCESS :
- Parsing structuré
- Extraction : ID exigence, description, criticité
- Validation optionnelle via LLM (cohérence structurée, anomalies de format)
OUTPUT :
- Remplissage de `checklists`
- Événement Redis :
```json
{
  "event": "checklist_ready",
  "audit_id": "..."
}
```

✅ PHASE 4 — AGENT 2 : EVIDENCE MAPPER (RAG)

Ce passage exploite explicitement Milvus. Il est central car il alimente la substance documentaire derrière chaque jugement.

INPUT :

- requirement.description
- embeddings des documents (Milvus)
PROCESS :
- Embedding de l’exigence
- Recherche top-k en similarité
- Sélection candidats
- LLM : filtre, justifie, détecte non correspondance/hallucination
OUTPUT :
```json
{
  "event": "evidence_mapped",
  "requirement_id": "...",
  "documents": [...],
  "coverage_score": 0.0
}
```
- Enregistré également dans `evidence_mapping`

✅ PHASE 5 — AGENT 3 : COMPLIANCE EVALUATOR

Combine état structuré + conteúdo sémantique + règles métier, avec registre décisionnel JSON.

INPUT :
```json
{
  "requirement": "...",
  "linked_documents": [...],
  "metadata": {...}
}
```
PROCESS :
Prompt structuré demandant une évaluation conforme à un format opérationnel :
```json
{
  "status": "conform / partial / non_conform",
  "justification": "...",
  "risk_level": "..."
}
```
OUTPUT :
- Mise à jour de `checklist.status`
- Événement Redis `compliance_evaluated`

✅ PHASE 6 — NON CONFORMITY MANAGER

INPUT : exigences avec `status = non_conform`
PROCESS :
- LLM génère : description NC, impact, recommandation initiale
OUTPUT :
- Remplissage `non_conformities`
- Événement `nc_generated`

✅ PHASE 7 — CAPA MANAGER

INPUT : événement `nc_generated`
PROCESS :
- LLM suggère action corrective, priorité, délai conseillé
- Validation humaine / ajustements
OUTPUT :
- `capa_actions`
- Événement `capa_updated`

✅ PHASE 8 — AUDIT REPORT GENERATOR

INPUT : checklist final, NC, CAPA, score global
PROCESS :
- Synthèse LLM → résumé exécutif, tableau conformité, score %, liste NC, plan CAPA
OUTPUT :
- Génération PDF
- Événement `audit_report_ready`

🔥 Stratégie multi-agent recommandée (ordre de mise en œuvre)

Pour éviter l'instabilité : ne pas aborder tous les agents simultanément.

Ordre conseillé :
1. ✅ Schéma DB
2. ✅ Ingestion documents
3. ✅ Milvus opérationnel
4. ✅ Checklist Manager
5. ✅ Evidence Mapper

6. ✅ Compliance Evaluator

Les étapes suivantes viennent au fil de l'extension, sans redépenser d'énergie sur l'ancrage de la donnée.

Analyse Critique des Choix Techniques & Modèles Open Source

1. Évaluation de l'Architecture Actuelle

Ce qui est BON ✅

CHOIX	VERDICT	RAISON
Milvus	✅	Meilleure vector DB open source pour production
Redis Pub/Sub	✅	Parfait pour event bus léger entre agents
Supabase	✅	PostgreSQL solide + API auto + Auth
LangGraph	✅	Idéal pour orchestration multi-agents stateful
FastAPI	✅	Standard industrie Python
pdfplumber	✅	Meilleur pour extraction PDF texte + tableaux

Ce qui mérite réflexion ⚠️

```
┌──────────────────────────────────────────────────────────────────────────────────────────────────────────────┐
│  CHOIX            │  PROBLÈME                                                                                  │
├──────────────────────────────────────────────────────────────────────────────────────────────────────────────┤
│  Ollama seul      │  Pas de fallback si modèle trop lent                                                       │
│                   │  Mistral 7B peut halluciner sur termes ISO                                                 │
├──────────────────────────────────────────────────────────────────────────────────────────────────────────────┤
│  pytesseract      │  OCR qualité moyenne sur docs industriels                                                  │
│                   │  Moins bon que EasyOCR sur images complexes                                                │
├──────────────────────────────────────────────────────────────────────────────────────────────────────────────┤
│  MiniLM seul      │  Dimensions 384 — peut manquer nuances ISO                                                 │
│                   │  Pas optimisé domaine audit/qualité                                                        │
├──────────────────────────────────────────────────────────────────────────────────────────────────────────────┤
│  ReportLab seul   │  Templates limités — Weasyprint + HTML                                                     │
│                   │  donne de meilleurs résultats visuels                                                      │
└──────────────────────────────────────────────────────────────────────────────────────────────────────────────┘
```

2. Benchmark Complet des Modèles LLM Open Source

2.1 Modèles pour le Raisonnement / Évaluation ISO

MODÈLE	TAILLE	VRAM MIN	SCORE /10	VITESSE	OLLAMA TAG
🥇 Mistral Nemo (recommandé #1) Mistral AI 2024	12B	8GB	8.5	Rapide	ollama pull mistral-nemo
🥈 Qwen2.5:14b (recommandé #2) Alibaba 2024	14B	10GB	8.7	Moyen	ollama pull qwen2.5:14b
🥉 LLaMA 3.1:8b (recommandé #3) Meta 2024	8B	6GB	8.2	Rapide	ollama pull llama3.1:8b
Gemma2:9b Google 2024	9B	6GB	8.0	Rapide	ollama pull gemma2:9b
Phi-3.5:mini Microsoft 2024	3.8B	4GB	7.5	Très Rapide	ollama pull phi3.5
DeepSeek-R1:8b DeepSeek 2025	8B	6GB	8.4	Moyen	ollama pull deepseek-r1:8b ⭐ Très bon raisonnement
Mistral 7B (ancien choix)	7B	5GB	7.8	Rapide	ollama pull mistral ❌ Remplacer par Nemo
Falcon2:11b	11B	8GB	7.3	Moyen	❌ Pas recommandé Moins bon en français

2.2 Notre Recommandation : Stratégie Multi-Modèles

```
┌──────────────────────────────────────────────────────────────────────────────┐
│                    ARCHITECTURE MULTI-MODÈLES RECOMMANDÉE                    │
├──────────────────────────────────────────────────────────────────────────────┤
│                                                                              │
│  TÂCHE LÉGÈRE (structuration, classification)                                │
│  → Phi-3.5:mini (3.8B) — ultra rapide, peu de RAM                            │
│                                                                              │
│  TÂCHE STANDARD (évaluation conformité, NC, CAPA)                            │
│  → LLaMA 3.1:8b OU Mistral Nemo:12b                                          │
│                                                                              │
│  TÂCHE COMPLEXE (rapport final, analyse juridique ISO)                       │
│  → Qwen2.5:14b OU DeepSeek-R1:8b                                             │
│                                                                              │
│  TÂCHE RAISONNEMENT (gap analysis critique)                                  │
│  → DeepSeek-R1:8b (chain-of-thought natif)                                   │
│                                                                              │
└──────────────────────────────────────────────────────────────────────────────┘
```

3. Benchmark Modèles d'Embedding

MODÈLE	DIM	LANG	SCORE	RAM	VERDICT
🥇 multilingual-e5-large Microsoft	1024	100+	9.1	2GB	✅ TOP Meilleur fr+en
🥈 bge-m3 BAAI (Beijing AI)	1024	100+	9.0	2GB	✅ TOP Dense + Sparse
🥉 paraphrase-multilingual-mpnet sentence-transformers	768	50+	8.5	1GB	✅ Bon Équilibré
paraphrase-multilingual-MiniLM (choix actuel)	384	50+	7.8	500MB	⚠️ Moyen Trop petit
camembert-base (uniquement fr)	768	FR only	8.2	500MB	⚠️ FR seulement
e5-mistral-7b-instruct (trop lourd)	4096	Multi	9.3	14GB	❌ Trop lourd

```
# MEILLEURE OPTION pour QualiNova (fr + en + arabe possible)
model = SentenceTransformer('intfloat/multilingual-e5-large')

# OU pour moins de RAM avec très bonne qualité
model = SentenceTransformer('BAAI/bge-m3')
```

4. Benchmark OCR

OUTIL	QUALITÉ	LANGUES	VITESSE	VERDICT
🥇 EasyOCR	★★★★☆	80+	Moyen	✅ Recommandé Deep learning Meilleur sur docs industriels
🥈 Tesseract 5 pytesseract	★★★☆☆	100+	Rapide	✅ Bon backup Léger en RAM
🥉 Surya OCR (nouveau)	★★★★★	90+	Lent	✅ Meilleur qualité 2024 Mais lourd
Doctr (mindee)	★★★★☆	Multi	Moyen	✅ Bon pour tableaux complexes
PaddleOCR	★★★★☆	80+	Rapide	⚠️ Config complexe

5. Stack Finale Recommandée (Révisée)

```
┌──────────────────────────────────────────────────────────────────────────────────────────────────────────────┐
│                                                                                                              │
│                                                STACK RÉVISÉE QUALINOVA                                       │
├──────────────────────────────────────────────────────────────────────────────────────────────────────────────┤
│                                                                                                              │
│  COMPOSANT                  │  CHOIX FINAL RECOMMANDÉ                                                        │
├──────────────────────────────────────────────────────────────────────────────────────────────────────────────┤
│                                                                                                              │
│  LLM Principal              │  Qwen2.5:14b                                                                   │
│  (évaluation, NC,           │  → Meilleur rapport qualité/taille                                             │
│   rapport)                  │  → Excellent en FR + EN                                                        │
│                             │  → Instruction following précis                                                │
├──────────────────────────────────────────────────────────────────────────────────────────────────────────────┤
│                                                                                                              │
│  LLM Léger                  │  Phi-3.5:mini (3.8B)                                                           │
│  (structuration,            │  → Ultra rapide (< 2s / requête)                                               │
│   classification)           │  → Parfait pour tâches simples                                                 │
├──────────────────────────────────────────────────────────────────────────────────────────────────────────────┤
│                                                                                                              │
│  LLM Raisonnement           │  DeepSeek-R1:8b                                                                │
│  (gap analysis,             │  → Chain-of-thought natif                                                      │
│   analyse critique)         │  → Meilleur pour raisonnement logique                                          │
├──────────────────────────────────────────────────────────────────────────────────────────────────────────────┤
│                                                                                                              │
│  Embeddings                 │  intfloat/multilingual-e5-large                                                │
│                             │  → 1024 dim — FR + EN — state of the art                                       │
├──────────────────────────────────────────────────────────────────────────────────────────────────────────────┤
│                                                                                                              │
│  OCR Principal              │  EasyOCR                                                                       │
│                             │  → Deep learning — meilleur qualité                                            │
├──────────────────────────────────────────────────────────────────────────────────────────────────────────────┤
│                                                                                                              │
│  OCR Backup                 │  pytesseract                                                                   │
│                             │  → Léger — fallback rapide                                                     │
├──────────────────────────────────────────────────────────────────────────────────────────────────────────────┤
│                                                                                                              │
│  Vector DB                  │  Milvus ✅ (garder)                                                            │
├──────────────────────────────────────────────────────────────────────────────────────────────────────────────┤
```

```
│ Vector DB          │ Milvus ✅ (garder)                          │
├────────────────────┼──────────────────────────────────────────────
────────────────────┤
│ Event Bus          │ Redis ✅ (garder)                           │
├────────────────────┼──────────────────────────────────────────────
────────────────────┤
│ Base de données    │ Supabase ✅ (garder)                        │
├────────────────────┼──────────────────────────────────────────────
────────────────────┤
│ Orchestration      │ LangGraph ✅ (garder)                       │
├────────────────────┼──────────────────────────────────────────────
────────────────────┤
│ Génération PDF     │ ReportLab + WeasyPrint (HTML→PDF)           │
│                    │ → Templates plus riches avec WeasyPrint     │
├────────────────────┼──────────────────────────────────────────────
────────────────────┤
│ Extraction PDF     │ pdfplumber ✅ + pymupdf (backup)            │
├────────────────────┼──────────────────────────────────────────────
────────────────────┤
│ Extraction DOCX    │ python-docx ✅ (garder)                     │
├────────────────────┼──────────────────────────────────────────────
────────────────────┤
│ API                │ FastAPI ✅ (garder)                         │
└────────────────────┴──────────────────────────────────────────────
────────────────────┘
```

6. Stratégie de Routage LLM par Agent

```
# config/llm_router.py

LLM_CONFIG = {

    # Agent 1 - Checklist Manager
    # Tâche : structurer une checklist → simple
    "checklist_manager": {
        "model": "phi3.5",        # 3.8B — rapide
        "temperature": 0.1,       # Très déterministe
        "max_tokens": 2048
    },

    # Agent 2 - Evidence Mapper
    # Tâche : valider pertinence doc → moyen
    "evidence_mapper": {
        "model": "llama3.1:8b",   # 8B — bon équilibre
        "temperature": 0.1,
        "max_tokens": 1024
    },
```

```
    # Agent 3 - Compliance Evaluator
    # Tâche : évaluation juridique ISO → complexe
    "compliance_evaluator": {
        "model": "qwen2.5:14b",   # 14B — précis
        "temperature": 0.05,      # Très factuel
        "max_tokens": 2048
    },

    # Agent 4 - NC Manager
    # Tâche : rédiger fiches NC → moyen/complexe
    "nc_manager": {
        "model": "qwen2.5:14b",   # 14B — rédaction pro
        "temperature": 0.2,
        "max_tokens": 1024
    },

    # Agent 5 - CAPA Manager
    # Tâche : plans d'action détaillés → moyen
    "capa_manager": {
        "model": "llama3.1:8b",   # 8B — assez bon
        "temperature": 0.3,       # Un peu créatif
        "max_tokens": 2048
    },

    # Agent 6 - Report Generator
    # Tâche : rédiger résumé exécutif → complexe
    "report_generator": {
        "model": "qwen2.5:14b",   # 14B — meilleure rédaction
        "temperature": 0.4,       # Plus fluide
        "max_tokens": 4096
    }
}
```

7. Configuration Docker Révisée

```
# docker-compose.yml — VERSION FINALE

services:

  # ── LLM Engine ──────────────────────────────────────
  ollama:
    image: ollama/ollama:latest
    ports:
      - "11434:11434"
    volumes:
```

```
    - ollama_data:/root/.ollama
  deploy:
    resources:
      reservations:
        devices:
          - driver: nvidia
            count: 1
            capabilities: [gpu]   # Si GPU dispo
  # Script init pour pull les modèles
  entrypoint: >
    sh -c "ollama serve &
           sleep 5 &&
           ollama pull phi3.5 &&
           ollama pull llama3.1:8b &&
           ollama pull qwen2.5:14b &&
           ollama pull deepseek-r1:8b &&
           wait"

# ── Vector DB ──────────────────────────────────────────
milvus:
  image: milvusdb/milvus:v2.4.0
  ports:
    - "19530:19530"
  environment:
    ETCD_ENDPOINTS: etcd:2379
    MINIO_ADDRESS: minio:9000
  depends_on:
    - etcd
    - minio

etcd:
  image: quay.io/coreos/etcd:v3.5.5
  environment:
    ETCD_AUTO_COMPACTION_MODE: revision
    ETCD_QUOTA_BACKEND_BYTES: "4294967296"

minio:
  image: minio/minio:latest
  environment:
    MINIO_ACCESS_KEY: minioadmin
    MINIO_SECRET_KEY: minioadmin
  command: minio server /data

# ── Cache & Events ─────────────────────────────────────
redis:
  image: redis:7-alpine
  ports:
    - "6379:6379"
```

```
    command: redis-server --maxmemory 2gb --maxmemory-policy allkeys-lru

  # ── Application ──────────────────────────────────────
  api:
    build: .
    ports:
      - "8000:8000"
    environment:
      SUPABASE_URL: ${SUPABASE_URL}
      SUPABASE_KEY: ${SUPABASE_KEY}
      REDIS_HOST: redis
      MILVUS_HOST: milvus
      OLLAMA_HOST: http://ollama:11434
      EMBEDDING_MODEL: intfloat/multilingual-e5-large
    depends_on:
      - redis
      - milvus
      - ollama

volumes:
  ollama_data:
```

8. Besoins Matériels Selon Configuration

CONFIG	RAM	GPU VRAM	MODÈLES UTILISABLES
Minimum (CPU only)	16GB RAM	0 (CPU)	phi3.5 + llama3.1:8b ⚠️ Lent (2-5 min/audit)
Recommandé (GPU entry)	32GB RAM	8GB VRAM (RTX3060)	+ qwen2.5:14b ✅ Bon (30s-1min)
Optimal (GPU mid)	64GB RAM	16GB VRAM (RTX4080)	Tous les modèles ✅ Excellent (< 30s)
Production	128GB RAM	24GB VRAM (A10G)	Parallélisation multi-modèles

9. Résumé des Changements à Faire

```
AVANT (choix initial)          APRÈS (recommandé)
═══════════════════════════    ═══════════════════════════

Mistral 7B (un seul)      →    3 modèles selon complexité
                               phi3.5 + llama3.1:8b + qwen2.5:14b

MiniLM-L12 (384 dim)      →    multilingual-e5-large (1024 dim)
                               +50% précision en français

pytesseract seul          →    EasyOCR principal + pytesseract backup
                               +40% qualité OCR docs industriels

ReportLab seul            →    ReportLab + WeasyPrint option
                               meilleurs templates HTML→PDF

Mistral 7B pour tout      →    DeepSeek-R1:8b pour raisonnement
                               chain-of-thought sur gap analysis

Milvus ✅                 →    Milvus ✅ (garder)
Redis ✅                  →    Redis ✅ (garder)
Supabase ✅               →    Supabase ✅ (garder)
LangGraph ✅              →    LangGraph ✅ (garder)
FastAPI ✅                →    FastAPI ✅ (garder)
```

⚠️ Le vrai enjeu maintenant : LES MODÈLES IA

Ton projet a 4 besoins IA différents :

1. 🔎 Retrieval / Embeddings
2. 🧠 Raisonnement conformité
3. 📄 Génération structurée (JSON fiable)
4. 📊 Résumé et rapport d'audit

Un seul modèle ne suffit pas toujours.

🥇 MEILLEURS MODÈLES OPEN SOURCE (2026)

Je vais te donner les modèles réellement performants aujourd'hui.

✅ 1️⃣ EMBEDDING MODELS (CRITIQUE POUR MILVUS)

🎯 Objectif : Similarité sémantique fiable pour audit documentaire

🥇 BGE-M3 (BAAI)

✅ Meilleur actuellement open-source
✅ Multilingue (FR inclus)
✅ Très bon pour documents longs
✅ Optimisé RAG

👉 RECOMMANDÉ

Alternative :

- e5-mistral-7b-instruct (plus lourd)
- Instructor-xl (ancien mais stable)

✅ Choix recommandé :

```text
BAAI/bge-m3
```

✅ 2️⃣ LLM PRINCIPAL (RAISONNEMENT + CONFORMITÉ)

Ton système doit :

- Analyser cohérence
- Détecter gaps
- Générer JSON structuré
- Éviter hallucination
- Comprendre documents techniques

🥇 Top Modèles Open Source Actuels

🥇 Llama 3.1 70B Instruct

✅ Très fort en raisonnement
✅ Stable en JSON structuré
✅ Excellent pour conformité
⚠️ Besoin GPU costaud

Si vous avez GPU A100 / H100 → parfait.

🥈 Mistral Large (open weights version entreprise)

Très bon mais moins accessible full free.

🥉 Mixtral 8x7B

✅ Très bon compromis performance/coût
✅ Multi-expert → bon raisonnement
✅ Plus léger que 70B

👉 Très bon choix pour startup.

🥇 Meilleur compromis réaliste startup :

Si vous avez :

- GPU moyen
- Budget limité

👉 **Mixtral 8×7B Instruct**
ou
👉 **Llama 3 8B Instruct** (si infra limitée)

🥇 **Meilleur compromis réaliste startup :**

Si vous avez :

- GPU moyen
- Budget limité

👉 **Mixtral 8×7B Instruct**
ou
👉 **Llama 3 8B Instruct** (si infra limitée)

✅ 3️⃣ Modèle léger pour tâches simples (optionnel)

Pour :

- Classification
- Tagging
- Détection statut simple

👉 Phi-3 Mini
Très efficace et ultra léger.

✅ STACK IA RECOMMANDÉE POUR QUALINOVA

🎯 Embeddings

```text
BAAI/bge-m3
```

🎯 LLM principal

Si GPU solide :

```text
Llama 3.1 70B Instruct
```

Sinon (recommandé startup) :

```text
Mixtral 8x7B Instruct
```

🎯 Petit modèle secondaire

```text
Phi-3 Mini
```

🚨 ERREUR À ÉVITER

Ne pas utiliser :

- ❌ petit modèle 3B pour raisonnement conformité
- ❌ embeddings génériques faibles
- ❌ RAG sans reranking
- ❌ LLM sans JSON schema enforcement

vLLM — Explication Complète & Simple

1. C'est Quoi vLLM en Termes Simples ?

Imagine un restaurant :

🍽️ OLLAMA = Un cuisinier seul
→ Il prend UNE commande
→ La cuisine
→ La sert
→ PUIS prend la commande suivante
→ Client 2 attend que Client 1 soit servi

🏭 vLLM = Une cuisine industrielle avec chef + équipe
→ Il prend 10 commandes EN MÊME TEMPS
→ Les cuisine en parallèle (batching)
→ Sert tout le monde presque simultanément
→ Beaucoup plus efficace pour BEAUCOUP de clients

2. Le Problème que vLLM Résout

SANS vLLM (Ollama) — 5 agents font des requêtes LLM en même temps :

```
Agent 1 ──────────────────────────────────────────────▶ LLM [▓▓▓▓▓▓▓▓▓▓] 8 sec
Agent 2 ──▶ attend ──────────────────────────────────▶ LLM [▓▓▓▓▓▓▓▓▓▓] 8 sec
Agent 3 ──▶ attend ──▶ attend ──────────────────────▶ LLM [▓▓▓▓▓▓▓▓▓▓] 8 sec
Agent 4 ──▶ attend ──▶ attend ──▶ att▶ LLM [▓▓▓▓▓▓▓▓▓▓] 8 sec
Agent 5 ──▶ attend x4 ──────────────────────────────▶ LLM [▓▓▓▓▓▓▓▓▓▓] 8 sec
                                Total : 40 sec ❌
```

AVEC vLLM — 5 agents font des requêtes LLM en même temps :

```
Agent 1 ──┐
Agent 2 ──┤
Agent 3 ──┼──▶ vLLM [▓▓▓▓▓▓▓▓▓▓▓▓▓▓] 12 sec (tous ensemble)
Agent 4 ──┤
Agent 5 ──┘
                Total : 12 sec ✅  (x3 plus rapide)
```

3. La Technologie Clé : PagedAttention

```
┌──────────────────────────────────────────────────────────────────────────────────────────────┐
│                                                                                              │
│                                  SANS PagedAttention                                         │
│                                     (Ollama)                                                 │
│                                                                                              │
│   GPU Memory (16GB)                                                                          │
│   ┌──────────────────────────────────────────────────────────────────────────────────┐       │
│   │                                                                                  │       │
│   │   Requête 1  [▓▓▓
```

```
┌──────────────────────────────────────────────────────────────────────────────────────────────────────────────────────────────────────────────────────────────────────────────┐
│                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                ARCHITECTURE QUALINOVA                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                MODULE AUDIT INTERNE                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                Agent 1 (Checklist Manager)                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                Agent 2 (Evidence Mapper)                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                Agent 3 (Compliance Evaluator)                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                Agent 4 (NC Manager)                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                Agent 5 (CAPA Manager)                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                Agent 6 (Report Generator)                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                Agent 1 (Diagnostic)                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                Agent 2 (Gap Analysis)                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                Agent 3 (Readiness Score)                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                
```

5. Comment On Lance vLLM — Pas à Pas

Étape 1 : Installation

```bash
# Prérequis : NVIDIA GPU + CUDA 11.8+

# Installer vLLM
pip install vllm

# OU avec Docker (recommandé)
docker pull vllm/vllm-openai:latest
```

Étape 2 : Lancer le serveur vLLM

```bash
# Option A — Ligne de commande directe
python -m vllm.entrypoints.openai.api_server \
```

```
    --model Qwen/Qwen2.5-14B-Instruct \
    --host 0.0.0.0 \
    --port 8000 \
    --dtype auto \
    --max-model-len 8192 \
    --gpu-memory-utilization 0.85
```

Option B — Docker

```
docker run --gpus all \
    -p 8000:8000 \
    -v ~/.cache/huggingface:/root/.cache/huggingface \
    vllm/vllm-openai:latest \
    --model Qwen/Qwen2.5-14B-Instruct \
    --dtype auto
```

Le serveur est maintenant disponible sur :

http://localhost:8000/v1

Compatible API OpenAI → nos agents se connectent directement

Étape 3 : Vérifier que ça marche

```bash
# Test simple avec curl
curl http://localhost:8000/v1/chat/completions \
  -H "Content-Type: application/json" \
  -d '{
    "model": "Qwen/Qwen2.5-14B-Instruct",
    "messages": [
      {
        "role": "user",
        "content": "Explique ISO 9001 en 2 phrases"
      }
    ],
    "temperature": 0.1
  }'

# Réponse attendue :
# {"choices": [{"message": {"content": "ISO 9001 est..."}}]}
```

6. Comment les Agents Se Connectent à vLLM

```python
# utils/llm_factory.py
# LE MÊME CODE fonctionne avec Ollama ET vLLM
# Seule l'URL change !
```

```
import os
from langchain_openai import ChatOpenAI

class LLMFactory:
    """
    Fabrique de LLM — Ollama en dev, vLLM en prod
    Les agents ne savent pas lequel ils utilisent
    """

    # Mapping agent → modèle selon complexité
    AGENT_MODEL_MAP = {

        # ── Tâches simples → petit modèle rapide ──
        "checklist_manager" : {
            "dev_model"  : "phi3.5",
            "prod_model" : "Qwen/Qwen2.5-3B-Instruct",
            "temperature": 0.1,
            "max_tokens" : 2048,
            "description": "Structuration checklist"
        },

        # ── Tâches moyennes → modèle intermédiaire ──
        "evidence_mapper" : {
            "dev_model"  : "llama3.1:8b",
            "prod_model" : "meta-llama/Llama-3.1-8B-Instruct",
            "temperature": 0.1,
            "max_tokens" : 1024,
            "description": "Validation pertinence documents"
        },

        # ── Tâches complexes → grand modèle précis ──
        "compliance_evaluator" : {
            "dev_model"  : "qwen2.5:14b",
            "prod_model" : "Qwen/Qwen2.5-14B-Instruct",
            "temperature": 0.05,
            "max_tokens" : 2048,
            "description": "Évaluation conformité ISO"
        },

        "nc_manager" : {
            "dev_model"  : "qwen2.5:14b",
            "prod_model" : "Qwen/Qwen2.5-14B-Instruct",
            "temperature": 0.2,
            "max_tokens" : 1024,
            "description": "Rédaction fiches NC"
        },
```

```
    "capa_manager" : {
        "dev_model"  : "llama3.1:8b",
        "prod_model" : "meta-llama/Llama-3.1-8B-Instruct",
        "temperature": 0.3,
        "max_tokens" : 2048,
        "description": "Plans d'actions CAPA"
    },

    "report_generator" : {
        "dev_model"  : "qwen2.5:14b",
        "prod_model" : "Qwen/Qwen2.5-14B-Instruct",
        "temperature": 0.4,
        "max_tokens" : 4096,
        "description": "Génération rapport final"
    },

    # ── Raisonnement logique → DeepSeek R1 ──
    "gap_analysis" : {
        "dev_model"  : "deepseek-r1:8b",
        "prod_model" : "deepseek-ai/DeepSeek-R1-Distill-Qwen-14B",
        "temperature": 0.1,
        "max_tokens" : 4096,
        "description": "Analyse d'écarts critique"
    },
}

def __init__(self):
    self.env = os.getenv("ENV", "development")

    # URLs des serveurs LLM
    if self.env == "production":
        # vLLM — deux serveurs selon taille modèle
        self.url_heavy = os.getenv(
            "VLLM_HEAVY_URL",
            "http://vllm-heavy:8000/v1"   # Grand modèle (14B)
        )
        self.url_light = os.getenv(
            "VLLM_LIGHT_URL",
            "http://vllm-light:8001/v1"   # Petit modèle (3B-8B)
        )
        print(f"🚀 vLLM Production — Heavy: {self.url_heavy}")
    else:
        # Ollama — un seul serveur local
        self.url_ollama = os.getenv(
            "OLLAMA_URL",
            "http://localhost:11434/v1"
        )
        print(f"🧪 Ollama Dev — {self.url_ollama}")
```

```
    def get_llm(self, agent_name: str) -> ChatOpenAI:
        """
        Retourne le LLM configuré pour cet agent
        Code identique que ce soit Ollama ou vLLM
        """

        # Récupérer la config de l'agent
        config = self.AGENT_MODEL_MAP.get(
            agent_name,
            self.AGENT_MODEL_MAP["evidence_mapper"]  # défaut
        )

        if self.env == "production":
            # ── Production : vLLM ──────────────────────────────────────
            model_name = config["prod_model"]

            # Choisir le serveur selon la taille du modèle
            is_heavy_model = "14B" in model_name or "32B" in model_name
            base_url = self.url_heavy if is_heavy_model else self.url_light

        else:
            # ── Développement : Ollama ─────────────────────────────────
            model_name = config["dev_model"]
            base_url   = self.url_ollama

        print(f"  🤖 Agent [{agent_name}] → {model_name} @ {base_url}")

        # API compatible OpenAI → MÊME code pour Ollama et vLLM
        return ChatOpenAI(
            model       = model_name,
            base_url    = base_url,
            api_key     = "not-needed",       # Ollama/vLLM n'ont pas besoin
            temperature = config["temperature"],
            max_tokens  = config["max_tokens"],
            timeout     = 120,                # 2 min max par requête
        )


# ────────────────────────────────────────────────────────────────────────────
# Instance globale — importée par tous les agents
# ────────────────────────────────────────────────────────────────────────────
llm_factory = LLMFactory()
```

Utilisation dans un Agent

```python
# agents/compliance_evaluator.py

from utils.llm_factory import llm_factory

class ComplianceEvaluatorAgent:

    def __init__(self):
        # L'agent demande son LLM à la factory
        # Il ne sait PAS si c'est Ollama ou vLLM
        self.llm = llm_factory.get_llm("compliance_evaluator")

    def evaluate(self, requirement: str, document: str) -> dict:

        from langchain.schema import HumanMessage, SystemMessage

        messages = [
            SystemMessage(content="""Tu es un auditeur ISO certifié expert.
Évalue si ce document prouve la conformité à l'exigence donnée.
Réponds UNIQUEMENT en JSON valide."""),

            HumanMessage(content=f"""
EXIGENCE : {requirement}

DOCUMENT : {document[:1500]}

Réponds en JSON :
{{
  "status": "conforme|partiellement_conforme|non_conforme",
  "score": 0.0,
  "justification": "...",
  "lacunes": [],
  "recommandations": []
}}""")
        ]

        # Appel identique — Ollama ou vLLM derrière
        response = self.llm.invoke(messages)

        import json
        text = response.content
        start = text.find('{')
        end   = text.rfind('}') + 1
        return json.loads(text[start:end])
```

---

7. Quand Lancer vLLM dans QualiNova

```
┌──────────────────────────────────────────────────────────────────────────────────────────────────────────────┐
│                                    SCÉNARIOS CONCRETS                                                        │
├──────────────────────────────────────────────────────────────────────────────────────────────────────────────┤
│                                                                                                              │
│  SCÉNARIO 1 : Tu développes seul sur ton PC                                                                  │
│  ┌──────────────────────────────────────────────────────────────────────────────────────────────────────┐    │
│  │ → Utilise Ollama                                                                                     │    │
│  │ → ollama pull qwen2.5:14b                                                                            │    │
│  │ → Simple, rapide à lancer                                                                            │    │
│  │ → CPU possible si pas de GPU                                                                         │    │
│  └──────────────────────────────────────────────────────────────────────────────────────────────────────┘    │
│                                                                                                              │
│  SCÉNARIO 2 : Tu testes avec une équipe (5-10 personnes)                                                     │
│  ┌──────────────────────────────────────────────────────────────────────────────────────────────────────┐    │
│  │ → Ollama suffit encore                                                                               │    │
│  │ → 1 serveur Ollama partagé                                                                           │    │
│  │ → GPU 8GB recommandé                                                                                 │    │
│  └──────────────────────────────────────────────────────────────────────────────────────────────────────┘    │
│                                                                                                              │
│  SCÉNARIO 3 : Démo cabinet d'audit (plusieurs audits en parallèle)                                           │
│  ┌──────────────────────────────────────────────────────────────────────────────────────────────────────┐    │
│  │ → Passer à vLLM                                                                                      │    │
│  │ → GPU 16GB minimum                                                                                   │    │
│  │ → docker-compose.prod.yml                                                                            │    │
│  │ → Zéro changement de code agent                                                                      │    │
│  └──────────────────────────────────────────────────────────────────────────────────────────────────────┘    │
│                                                                                                              │
│  SCÉNARIO 4 : Production SaaS (100+ utilisateurs)                                                            │
│  ┌──────────────────────────────────────────────────────────────────────────────────────────────────────┐    │
│  │ → vLLM multi-GPU                                                                                     │    │
│  │ → --tensor-parallel-size 2                                                                           │    │
│  │ → Kubernetes + autoscaling                                                                           │    │
│  └──────────────────────────────────────────────────────────────────────────────────────────────────────┘    │
│                                                                                                              │
└──────────────────────────────────────────────────────────────────────────────────────────────────────────────┘
```

---

8. Résumé Ultra Simple

```
┌──────────────────────────────────────────────────────────────────────────────────────────────────────────────┐
│                                                                                                              │
│  vLLM = Un serveur Web qui héberge ton modèle LLM                                                            │
│                                                                                                              │
│  Tu le lances UNE FOIS avec une commande                                                                     │
│      ↓                                                                                                       │
│  Il écoute sur http://localhost:8000                                                                         │
│      ↓                                                                                                       │
│  Tes 6 agents envoient leurs prompts à cette URL                                                             │
│      ↓                                                                                                       │
│  vLLM gère les requêtes en parallèle avec PagedAttention                                                     │
│      ↓                                                                                                       │
│  Retourne les réponses JSON (même format qu'OpenAI API)                                                     │
│                                                                                                              │
│                                                                                                              │
└──────────────────────────────────────────────────────────────────────────────────────────────────────────────┘

┌──────────────────────────────────────────────────────────────────────────────────────────────────────────────┐
│                                                                                                              │
│  OLLAMA  → Pour développer et tester (maintenant)                                                            │
│  vLLM    → Pour déployer en production (plus tard)                                                           │
│                                                                                                              │
│  CODE IDENTIQUE dans les deux cas ✅                                                                         │
│  Seule l'URL change dans le .env ✅                                                                          │
│                                                                                                              │
└──────────────────────────────────────────────────────────────────────────────────────────────────────────────┘
```

En une phrase : vLLM est le moteur qui fait tourner ton LLM de façon industrielle — tu commences avec Ollama, tu passes à vLLM quand tu as besoin de performance pour plusieurs utilisateurs simultanés.